

LAPORAN PRAKTIKUM 2 PRAPROSES DATA

1. Dataset

Dataset yang digunakan pada praktikum ini adalah dataset House Prices – Advanced Regression Techniques yang diperoleh dari Kaggle. Dataset yang digunakan adalah train.csv. Dataset ini berisi data mengenai karakteristik rumah yang digunakan untuk memprediksi harga rumah (SalePrice).

Pada tahap pertama, dataset dibaca menggunakan library Pandas. Setelah dilakukan pengecekan menggunakan head(), shape(), dan info(), diketahui bahwa dataset memiliki 1.460 baris dan 81 atribut.

```
Jumlah baris dan kolom: (1460, 81)
<class 'pandas.DataFrame'>
RangeIndex: 1460 entries, 0 to 1459
Data columns (total 81 columns):
#   Column                Non-Null Count  Dtype  
---  -
0   Id                     1460 non-null   int64  
1   MSSubClass              1460 non-null   int64  
2   MSZoning                1460 non-null   str      
3   LotFrontage            1201 non-null   float64  
4   LotArea                1460 non-null   int64  
5   Street                 1460 non-null   str      
6   Alley                  91 non-null     str      
7   LotShape               1460 non-null   str      
8   LandContour            1460 non-null   str      
9   Utilities              1460 non-null   str      
10  LotConfig              1460 non-null   str      
11  LandSlope               1460 non-null   str      
12  Neighborhood            1460 non-null   str      
13  Condition1              1460 non-null   str      
14  Condition2              1460 non-null   str      
15  BldgType                1460 non-null   str      
16  HouseStyle              1460 non-null   str      
17  OverallQual             1460 non-null   int64  
18  OverallCond             1460 non-null   int64  
...
79  SaleCondition           1460 non-null   str      
80  SalePrice               1460 non-null   int64  
dtypes: float64(3), int64(35), str(43)
```

2. Cleaning Data

Tahap pertama dalam praproses adalah melakukan pengecekan terhadap missing value. Pengecekan dilakukan menggunakan df.isna().sum(). Dari hasil pengecekan, terdapat beberapa atribut yang memiliki missing value, seperti LotFrontage, Alley, MasVnrType, BsmtQual, FireplaceQu, PoolQC, Fence, dan beberapa atribut lainnya.


Selanjutnya, dilakukan pengecekan terhadap proporsi missing value pada setiap atribut. Atribut yang memiliki missing value lebih dari 50% dihapus karena jumlah data yang hilang pada atribut tersebut terlalu banyak. Atribut yang dihapus adalah Alley, MasVnrType, PoolQC, Fence, dan MiscFeature. Setelah lima atribut tersebut dihapus, ukuran dataset berubah dari 1.460 x 81 menjadi 1.460 x 76.

Untuk missing value yang tersisa dilakukan penanganan berdasarkan jenis atributnya. Pada atribut numerik, LotFrontage diisi menggunakan nilai median, sedangkan MasVnrArea dan GarageYrBltdiisi dengan nilai 0. Pada atribut kategorikal seperti BsmtQual, BsmtCond,


BsmtExposure, BsmtFinType1, BsmtFinType2, FireplaceQu, GarageType, GarageFinish, GarageQual, dan GarageCond, nilai yang kosong diisi dengan “None”. Untuk atribut Electrical, missing value diisi menggunakan nilai modus. Setelah proses tersebut dilakukan, pengecekan menunjukkan tidak terdapat missing value pada dataset.

3. Deteksi dan Penanganan Outlier

Setelah proses cleaning, dilakukan pengecekan outlier pada atribut numerik menggunakan boxplot. Boxplot dibuat untuk seluruh atribut numerik pada dataset agar dapat melihat atribut yang memiliki nilai yang cukup jauh dari sebagian besar data.



Dari hasil pengamatan boxplot, salah satu atribut yang memiliki nilai ekstrem adalah GrLivArea, yaitu luas area tempat tinggal di atas tanah. Untuk melihat outlier dengan lebih jelas, dibuat boxplot khusus untuk atribut tersebut.



Penentuan outlier dilakukan menggunakan metode IQR (Interquartile Range). Hasil perhitungan menunjukkan nilai Q1 sebesar 1129,5 dan Q3 sebesar 1776,75, sehingga nilai IQR adalah:


$$\text{IQR} = Q3 - Q1 = 1776,75 - 1129,5 = 647,25$$

Berdasarkan nilai tersebut, batas atas outlier dihitung dengan:

$$\text{Batas atas} = Q3 + 1,5 \times \text{IQR} = 2747,625$$

Data GrLivArea yang memiliki nilai lebih dari 2747,625 dianggap sebagai data yang berada di luar batas atas. Dari hasil pengecekan terdapat 31 data yang memenuhi kondisi tersebut.

Pada praktikum ini, outlier tidak langsung dihapus karena nilai luas rumah yang besar masih mungkin merupakan data yang valid. Oleh karena itu, dilakukan penanganan menggunakan metode capping, yaitu membatasi nilai GrLivArea yang lebih besar dari batas atas menjadi 2747,625. Setelah dilakukan capping, jumlah baris dataset tetap 1.460 baris, tetapi nilai maksimum GrLivArea menjadi 2747,625.




4. Transformasi Data

Setelah data dibersihkan, dilakukan pemisahan antara atribut yang digunakan sebagai fitur dan target. Atribut SalePrice digunakan sebagai target yang ingin diprediksi, sedangkan Id tidak digunakan sebagai fitur karena hanya berfungsi sebagai identitas data. Hasil pemisahan menghasilkan 74 fitur dengan 1.460 data dan target SalePrice sebanyak 1.460 data.

Selanjutnya, dilakukan One-Hot Encoding pada atribut kategorikal. Proses ini mengubah data kategorikal menjadi beberapa kolom yang berisi nilai 0 dan 1 sehingga dapat diproses dalam tahap berikutnya. Setelah One-Hot Encoding, jumlah fitur bertambah dari 74 menjadi 281 fitur. Setelah itu dilakukan standardisasi menggunakan StandardScaler. Standardisasi dilakukan agar skala setiap atribut menjadi lebih seragam. Hasil standardisasi menunjukkan rata-rata data mendekati 0 dan standar deviasi sebesar 1.


5. Analisis Korelasi dan Pengurangan Dimensi

Tahap selanjutnya adalah melihat hubungan antar atribut numerik menggunakan correlation heatmap. Korelasi digunakan untuk mengetahui apakah terdapat atribut yang memiliki hubungan yang sangat tinggi satu sama lain.



Dari hasil analisis korelasi, ditemukan beberapa pasangan atribut dengan nilai korelasi di atas 0,8, yaitu 1stFlrSF dan TotalBsmtSF dengan korelasi 0.8195, lalu TotRmsAbvGrd dan GrLivArea dengan korelasi 0.8356, serta GarageArea dan GarageCars dengan korelasi 0.8825. Karena terdapat beberapa atribut yang memiliki korelasi cukup tinggi, dilakukan pengurangan atribut untuk mengurangi informasi yang terlalu mirip. Atribut yang dihapus adalah TotalBsmtSF, TotRmsAbvGrd, dan GarageArea. Setelah pengurangan atribut, jumlah fitur berubah dari 281 menjadi 278 fitur. Setelah itu dilakukan standardisasi kembali sebelum masuk ke tahap PCA.

Selanjutnya, digunakan PCA (Principal Component Analysis) untuk mengurangi jumlah dimensi data. PCA digunakan dengan mempertahankan sekitar 95% variance dari data. Hasilnya, jumlah fitur berhasil dikurangi dari 278 fitur menjadi 170 komponen.



Grafik tersebut menunjukkan hubungan antara jumlah komponen PCA dengan Cumulative Explained Variance. Dengan menggunakan 95% variance sebagai batas yang dipertahankan, diperoleh 170 komponen dari 278 fitur awal pada tahap PCA.

6. Ringkasan Dataset Setelah Praproses

Setelah seluruh tahapan praproses dilakukan, dataset hasil cleaning memiliki ukuran 1.460 baris dan 76 atribut. Seluruh missing value pada dataset telah ditangani sehingga jumlah missing value akhir adalah 0.

Pada tahap outlier, terdapat 31 data GrLivArea yang berada di atas batas atas IQR. Data tersebut tidak hapus, tetapi dilakukan capping dengan batas atas 2747,625 sehingga jumlah data tetap 1.460 baris.

Untuk tahap transformasi, data fitur yang awalnya terdiri dari 74 atribut berubah menjadi 281 atribut setelah dilakukan One-Hot Encoding. Setelah dilakukan analisis korelasi dan pengurangan atribut, jumlah fitur menjadi 278. Kemudian, PCA menghasilkan 170 komponen dengan mempertahankan 95% variance.

Secara keseluruhan, tahapan praproses yang dilakukan terdiri dari pengecekan dan penanganan missing value, deteksi dan penanganan outlier, One-Hot Encoding, standarisasi, analisis korelasi, pengurangan atribut, dan PCA. Dataset hasil cleaning kemudian disimpan dalam format CSV untuk digunakan sebagai hasil akhir dari proses pembersihan data.