

LAPORAN ANALISIS SCRAPPING DAN EDA

1. Deskripsi Dataset

Dataset diperoleh melalui proses scraping dari website CompaniesMarketCap.com yang menyediakan informasi mengenai perusahaan berdasarkan market capitalization. Data yang ada terdiri dari 1.500 perusahaan dengan 6 atribut, yaitu rank, nama_perusahaan, market_cap_usd_billion, harga_usd, perubahan_harian_persen, dan negara.

Atribut rank menunjukkan peringkat perusahaan berdasarkan market capitalization. nama_perusahaan dan negara merupakan data kategorikal, sedangkan market_cap_usd_billion, harga_usd, dan perubahan_harian_persen merupakan data numerik.

Data hasil scraping terlebih dahulu disimpan dalam bentuk csv sebagai raw dataset sebelum dilakukan proses cleaning dan transformasi data.

2. Statistik Deskriptif

Hasil statistik deskriptif menunjukkan bahwa nilai mean market capitalization dari 1.500 perusahaan adalah 86,24 miliar USD, dengan median sebesar 33,87 miliar USD dan nilai max mencapai 5.271 miliar USD. Perbedaan antara mean dan median menunjukkan bahwa distribusi market capitalization ini cenderung miring ke kanan, karena terdapat beberapa perusahaan dengan market cap yang jauh lebih besar dibandingkan sebagian besar perusahaan lainnya.

Untuk harga saham, nilai mean adalah 158,46 USD, sedangkan mediannya 58,44 USD, dengan nilai max sebesar 10.315 USD. Hal ini menunjukkan adanya beberapa perusahaan dengan harga saham yang sangat tinggi.

Sementara itu, rata-rata perubahan harian adalah 1,35% dengan median 0,92% dan nilai max 12,44%. Nilai ini menunjukkan bahwa sebagian besar perusahaan memiliki perubahan harian yang relatif kecil, sedangkan beberapa Perusahaan memiliki perubahan yang lebih besar

3. Penanganan Data

Berdasarkan pemeriksaan data, tidak ditemukan missing values pada seluruh atribut. Selain itu, tidak ditemukan duplikasi seluruh baris, duplikasi rank, ataupun duplikasi nama perusahaan.

Outlier dideteksi menggunakan metode IQR (Interquartile Range). Hasilnya ditemukan 164 outlier pada market capitalization, 122 outlier pada harga saham, dan 89 outlier pada perubahan harian. Outlier tidak dihapus karena nilai tersebut merupakan data yang valid dan dapat menggambarkan perusahaan dengan market capitalization atau harga saham yang jauh lebih tinggi maupun perubahan harga yang lebih besar dibandingkan perusahaan lainnya.

4. Visualisasi Data

Histogram Distribusi Market Capitalization bahwa sebagian besar perusahaan memiliki market capitalization yang relatif rendah, sedangkan hanya sebagian kecil perusahaan yang memiliki market capitalization yang sangat tinggi. Distribusi tersebut cenderung right-skewed yang sesuai dengan perbedaan antara nilai mean dan median.

Histogram Distribusi Perubahan Harian menunjukkan bahwa sebagian besar perusahaan memiliki perubahan harga harian yang relatif kecil. Hanya sebagian kecil perusahaan yang memiliki perubahan harian yang cukup besar.

Bar Chart Negara menunjukkan bahwa jumlah perusahaan pada setiap negara tidak merata. Terdapat beberapa negara yang memiliki jumlah perusahaan yang jauh lebih banyak dibandingkan negara lainnya, sehingga persebaran perusahaan dalam dataset terpusat pada negara-negara tertentu.

Scatter Plot Market Cap dan Harga Saham menunjukkan bahwa hubungan antara market capitalization dan harga saham tidak membentuk pola linear yang kuat. Hal ini juga didukung oleh nilai korelasi sebesar 0,072 yang menunjukkan korelasi positif tetapi sangat lemah.

Correlation Heatmap menunjukkan bahwa sebagian besar pasangan variabel memiliki korelasi yang sangat lemah atau mendekati nol. Korelasi paling kuat di sini terdapat antara rank dan market_cap_usd_billion, yaitu -0,34. Korelasi negatif ini menunjukkan bahwa perusahaan dengan rank yang semakin besar cenderung memiliki market capitalization yang semakin kecil. Sementara itu, market_cap_usd_billion dan perubahan_harian_persen memiliki korelasi sebesar 0,000086, sehingga hampir tidak terdapat hubungan linear antara kedua variabel tersebut.

5. Kesimpulan

Berdasarkan proses scraping dan EDA pada 1.500 perusahaan, dataset berhasil dikumpulkan dan dibersihkan tanpa missing values ataupun data duplikat. Analisis statistik menunjukkan bahwa market capitalization dan harga saham memiliki distribusi yang cenderung miring ke kanan karena adanya beberapa nilai yang sangat tinggi.

Deteksi IQR menunjukkan adanya outlier pada market capitalization, harga saham, dan perubahan harian. Outlier tersebut tetap dipertahankan karena merupakan bagian dari karakteristik data perusahaan. Berdasarkan visualisasi dan correlation heatmap, sebagian besar variabel memiliki hubungan linear yang lemah, dengan korelasi paling terlihat antara rank dan market capitalization.