Laporan Praktikum Ensemble

1. Pendahuluan

   Pada praktikum ini dilakukan klasifikasi data transaksi credit cart menggunakan metode Ensemble, yaitu Random Forest. Dataset yang digunakan adalah Credit Card Fraud Detection dari Kaggle yang berisi data transaksi credit card dengan dua kelas, yaitu transaksi normal (Class 0) dan transaksi penipuan atau fraud (Class 1).

   Permasalahan utama pada dataset ini adalah distribusi class yang tidak seimbang (class imbalance). Jumlah transaksi normal jauh lebih banyak dibandingkan transaksi fraud. Kondisi tersebut dapat menyebabkan model lebih cenderung mengenali transaksi normal dan kurang baik dalam mendeteksi transaksi penipuan (fraud).

   Untuk mengatasi permasalahan tersebut, dilakukan perbandingan antara model Random Forest tanpa penanganan class imbalance dan model Random Forest yang menggunakan metode *Synthetic Minority Over-sampling Technique* (SMOTE). Kedua model kemudian dievaluasi menggunakan precision, recall, F1-score, ROC-AUC, dan confusion matrix untuk mengetahui perbedaan hasil klasifikasinya.

2. Hasil dan Pembahasan

   2.1. Import dan Pemahaman Dataset

   Dataset diimpor dengan library pandas. Berdasarkan hasil pemeriksaan, dataset memiliki 284.807 baris dan 31 kolom, dengan penggunaan memori sekitar 67,4 MB.

   Dari hasil info(), seluruh kolom memiliki jumlah data terisi sebanyak 284.807 baris sehingga tidak ditemukan missing value pada dataset. Sebanyak 30 kolom bertipe numerik float64, sedangkan kolom Class bertipe integer. Kolom Class digunakan sebagai label untuk menentukan apakah suatu transaksi termasuk normal atau fraud.

   Dataset memiliki kolom Time, V1 sampai V28, Amount, dan Class. Kolom Time menunjukkan waktu transaksi, sedangkan Amount menunjukkan jumlah transaksi. Kolom V1 sampai V28 merupakan fitur numerik hasil transformasi PCA pada dataset. Dengan demikian, sebagian besar fitur yang digunakan tidak berupa informasi transaksi dalam bentuk aslinya.

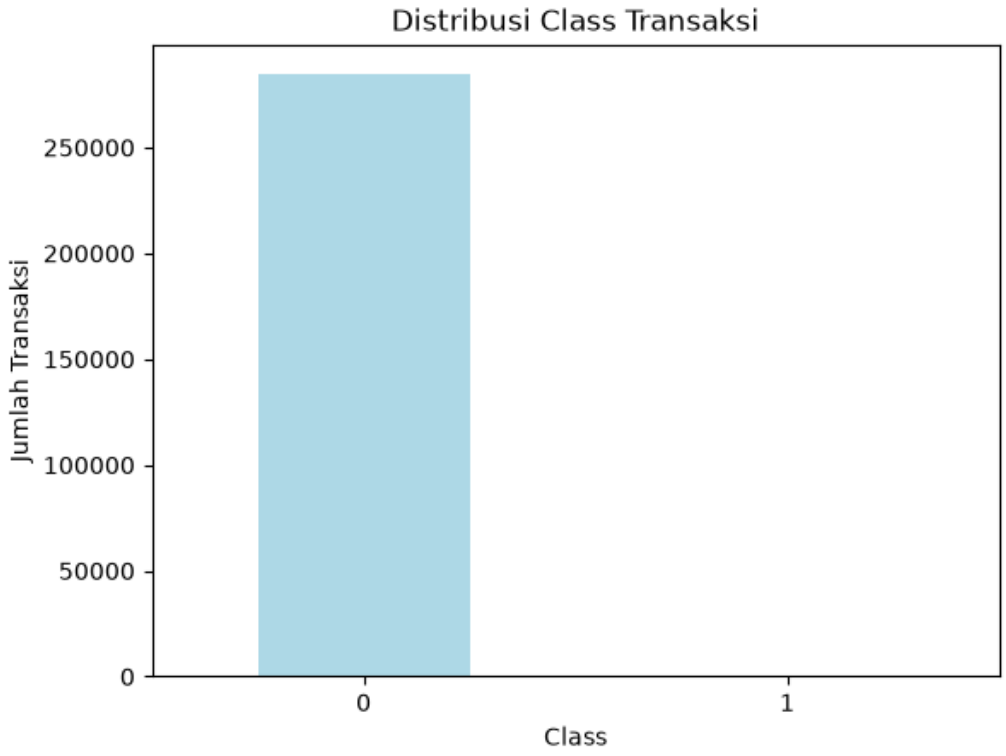
   2.2. Analisis Distribusi Class

   Sebelum membangun model, dilakukan pemeriksaan jumlah dan persentase setiap kelas pada kolom Class. Hasilnya menunjukkan bahwa distribusi kelas pada dataset sangat tidak seimbang.

Class	Keterangan	Jumlah Transaksi	Persentase
0	Normal	284.315	99,8273%
1	Fraud	492	0,1727%
Total		284.807	100%

Berdasarkan hasil tersebut, transaksi normal mendominasi dataset, sedangkan transaksi fraud hanya berjumlah 492 transaksi. Jadi, dari setiap 1.000 transaksi, hanya sekitar 1 hingga 2 transaksi yang termasuk fraud.

Hasil visualisasi distribusi class juga menunjukkan perbedaan jumlah yang sangat besar antara kedua kelas. Bar untuk Class 0 terlihat jauh lebih tinggi dibandingkan Class 1 sehingga bar kelas minoritas hampir tidak terlihat pada grafik. Kondisi ini menunjukkan bahwa penggunaan accuracy saja belum cukup untuk menilai kemampuan model. Model dapat menghasilkan accuracy yang tinggi dengan memprediksi sebagian besar transaksi sebagai normal, tetapi belum tentu mampu mendeteksi transaksi fraud dengan baik.



2.3. Data Preprocessing dan Pembagian Dataset

Pada tahap preprocessing, kolom Class dipisahkan dari fitur lainnya. Kolom Class digunakan sebagai variabel target (y), sedangkan kolom Time, V1 sampai V28, dan Amount digunakan sebagai fitur (X). Kemudian, dataset dibagi menjadi data train dan data test dengan perbandingan 80:20. Pembagian dilakukan menggunakan train_test_split dengan stratify=y dan random_state=42. Penggunaan stratify bertujuan mempertahankan proporsi kedua kelas pada data train dan data test agar distribusinya tetap mewakili dataset awal.

Data train digunakan untuk membangun model, sedangkan data test digunakan untuk mengevaluasi performa model terhadap data yang tidak digunakan dalam

train. Setelah pembagian, data test terdiri atas 56.864 transaksi normal dan 98 transaksi fraud.

2.4. Penerapan Random Forest dan SMOTE

Metode ensemble yang digunakan pada praktikum ini adalah Random Forest. Metode ini membangun sejumlah decision tree dan menggabungkan hasil prediksinya untuk menentukan kelas akhir. Pada praktikum ini, model menggunakan 20 decision tree (n_estimators=20), kedalaman maksimum 5 (max_depth=5), dan random_state=42.

Pengujian dilakukan dengan dua pendekatan. Pendekatan pertama menggunakan Random Forest tanpa penanganan class imbalance. Pendekatan kedua menggunakan Random Forest setelah data train diseimbangkan dengan SMOTE.

SMOTE merupakan metode oversampling yang membuat sampel sintetis untuk kelas minoritas berdasarkan hubungan antarsampel yang ada. Pada praktikum ini, SMOTE diterapkan hanya pada data train, sedangkan data test tetap menggunakan distribusi aslinya. Hal ini dilakukan agar evaluasi model tetap mencerminkan kondisi data yang tidak seimbang.

Dengan demikian, perbedaan hasil kedua model dapat digunakan untuk melihat pengaruh penerapan SMOTE terhadap kemampuan Random Forest dalam mengenali transaksi fraud.

2.5. Hasil Evaluasi Model

Evaluasi dilakukan menggunakan precision, recall, F1-score, ROC-AUC, dan confusion matrix.

Metrik Class 1 (Fraud)	Tanpa SMOTE	Dengan SMOTE
Precision	0,91	0,16
Recall	0,69	0,89
F1-score	0,79	0,27
ROC-AUC	0,9615	0,9703
Accuracy	99,93%	99,18%

Berdasarkan table, terdapat perbedaan performa antara kedua model. Model tanpa SMOTE menghasilkan precision sebesar 0,91 yang berarti sebagian besar transaksi yang diprediksi sebagai fraud memang termasuk fraud. Namun, recall sebesar 0,69 menunjukkan bahwa model masih melewatkan sebagian transaksi penipuan.

Sementara itu, model dengan SMOTE menghasilkan recall sebesar 0,89. Nilai ini menunjukkan bahwa model mampu mendeteksi lebih banyak transaksi fraud dibandingkan model tanpa SMOTE. Meskipun demikian, precision turun menjadi 0,16. Hal ini menunjukkan bahwa lebih banyak transaksi yang diprediksi sebagai fraud ternyata merupakan transaksi normal.

F1-score model tanpa SMOTE sebesar 0,79, sedangkan model dengan SMOTE sebesar 0,27. Penurunan tersebut menunjukkan bahwa peningkatan recall setelah SMOTE diikuti oleh penurunan ketepatan prediksi fraud yang cukup besar.

Nilai ROC-AUC meningkat dari 0,9615 menjadi 0,9703 setelah SMOTE. Nilai tersebut menunjukkan bahwa kemampuan model dalam membedakan kelas berdasarkan skor probaiblitasnya tergolong tinggi pada data test, Namun, ROC-AUC yang lebih tinggi tidak secara otomatis berarti bahwa seluruh hasil klasifikasi model menjadi lebih baik. Hal ini terlihat dari penurunan precision dan F1-score setelah penerapan SMOTE.

	precision	recall	f1-score	support
0	1.00	1.00	1.00	56864
1	0.91	0.69	0.79	98
accuracy			1.00	56962
macro avg	0.95	0.85	0.89	56962
weighted avg	1.00	1.00	1.00	56962

2.6. Analisis Confusion Matrix

Confusion matrix digunakan untuk mengetahui jumlah prediksi benar dan salah pada masing-masing kelas. Hasil pengujian kedua model adalah sebagai berikut.

- Model tanpa SMOTE

	Prediksi Normal	Prediksi Fraud
Aktual Normal	56.857	7
Aktual Fraud	30	68

Model tanpa SMOTE berhasil mengklasifikasikan 56.857 transaksi normal dan mendeteksi 68 transaksi fraud. Namun, terdapat 30 transaksi fraud yang salah diprediksi sebagai normal. Selain itu, terdapat 7 transaksi normal yang salah ditandai sebagai fraud.

- Model dengan SMOTE

	Prediksi Normal	Prediksi Fraud
Aktual Normal	56.409	455
Aktual Fraud	11	87

Setelah penerapan SMOTE, jumlah transaksi fraud yang berhasil dideteksi meningkat dari 68 menjadi 87. Jumlah transaksi fraud yang terlewat juga menurun dari 30 menjadi 11. Akan tetapi, jumlah transaksi normal yang salah diprediksi sebagai fraud meningkat dari 7 menjadi 455. Hasil ini memperlihatkan bahwa penerapan SMOTE membuat model lebih sensitive

terhadap transaksi fraud, tetapi juga meningkatkan jumlah kesalahan berupa penandaan transaksi normal sebagai fraud. Dalam penerapannya, kesalahan tersebut dapat menyebabkan transaksi normal perlu diperiksa lebih lanjut.

2.7. Mengapa Accuracy Saja Tidak Cukup

Accuracy mengukur proporsi seluruh prediksi yang benar dibandingkan dengan jumlah seluruh data. Pada dataset yang tidak seimbang, nilai accuracy dapat terlihat tinggi karena sebagian besar data berasal dari kelas mayoritas. Sebagai contoh, model yang selalu memprediksi seluruh transaksi sebagai normal sudah dapat memperoleh accuracy sekitar 99,83% pada dataset awal. Namun, model tersebut sama sekali tidak mampu mendeteksi transaksi fraud.

Oleh karena itu, precision, recall, F1-score, ROC-AUC, dan confusion matrix diperlukan untuk memberikan gambaran performa yang lebih lengkap. Pada kasus deteksi fraud, recall penting untuk mengetahui berapa banyak transaksi penipuan yang berhasil ditemukan, sedangkan precision membantu menilai seberapa tepat prediksi fraud yang dihasilkan model.

3. Kesimpulan

Berdasarkan praktikum yang telah dilakukan, dataset Credit Card Fraud Detection memiliki masalah class imbalance karena transaksi normal mencapai 99,8273%, sedangkan transaksi fraud hanya 0,1727%. Kondisi ini membuat evaluasi model perlu memperhatikan kemampuan mendeteksi kelas minoritas, bukan hanya accuracy. Model Random Forest tanpa SMOTE memperoleh precision 0,91, recall 0,69, F1-score 0,79, dan ROC-AUC 0,9615 pada kelas fraud. Setelah menggunakan SMOTE pada data train, recall meningkat menjadi 0,89 dan ROC-AUC menjadi 0,9703. Namun, precision turun menjadi 0,16 dan F1-score menjadi 0,27 karena meningkatnya jumlah transaksi normal yang salah diprediksi sebagai fraud.

Dengan demikian, SMOTE memberikan manfaat dalam meningkatkan jumlah transaksi fraud yang berhasil terdeteksi, tetapi juga menimbulkan lebih banyak prediksi fraud yang keliru. Pemilihan model terbaik perlu disesuaikan dengan kebutuhan sistem, terutama keseimbangan antara transaksi fraud yang terlewat dan transaksi normal yang salah ditandai sebagai fraud. Praktikum ini menunjukkan bahwa penanganan class imbalance dapat memengaruhi hasil klasifikasi secara signifikan. Oleh karena itu, penggunaan beberapa metrik evaluasi diperlukan untuk memahami kelebihan dan kekurangan model sebelum diterapkan pada kasus nyata.